11. Синхронный consensus: отказы и точная модель рассылки

Цель. Сформулировать задачу согласования без двусмысленности и построить два протокола для разных синхронных моделей отказов. Один и тот же аргумент «все видят одинаковое» верен, когда отказ происходит между раундами, и ложен, когда процесс может отправить сообщение лишь части адресатов. Для второго случая мы докажем отдельный двухраундный протокол.

1. Свойства задачи

Определение 11.1 (бинарный consensus). Даны $n \geq 2$ процессов с входами $x_i \in \{0,1\}$. Процесс может необратимо объявить $d_i \in \{0,1\}$. При не более f crash failures требуются: **uniform agreement** — никакие два процесса, когда-либо объявившие решение, не объявляют разные значения, даже если один из них позже отказал; **unanimity validity** — если все входы равны b, всякое решение равно b; **termination** — каждый неотказавший процесс когда-нибудь решает. Эту сильную форму agreement используем и в синхронной, и в асинхронной частях курса.

Слабая validity «решённое значение предложено некоторым процессом» совпадает с unanimity validity для бинарных входов при единогласии, но вне единогласия может разрешать оба бита. Нельзя доказать алгоритм только ссылкой на agreement: константный вывод 0 всегда согласован, но нарушает validity на входе из одних единиц. Нельзя доказать только safety: ожидание всех входов безопасно без отказов, но зависает при crash.

Пример. При входах $(0,1,1)$ решение 0 допустимо по validity, как и решение 1; требуется, чтобы все исправные выбрали одно и то же. Если входы $(1,1,1)$, решение 0 запрещено. Базовая постановка асинхронного consensus и роль отказа: Fischer–Lynch–Paterson, 1985, §1–2.

2. Сильный синхронный раунд

Определение 11.2 (отказ на границе раунда). В каждом раунде каждый процесс либо активен весь раунд и посылает сообщение всем адресатам, либо уже отказал до его начала и не посылает никому. Каналы между активными доставляют сообщения к концу раунда. Сеть полная, процессы знают множество ID участников; размер сообщения не ограничен.

Алгоритм 11.3. В первом раунде каждый активный процесс рассылает пару (i, x_i). В конце раунда каждый активный процесс решает минимум битов в полученных парах, включая собственную.

Теорема 11.4. При $f < n$ алгоритм 11.3 удовлетворяет agreement, validity и termination за один раунд.

Доказательство. Все активные процессы получают пары от одного и того же множества отправителей: в модели 11.2 процесс послал либо всем, либо никому. Это множество непусто, поскольку $f < n$. Детерминированная функция минимума даёт одинаковые решения, то есть agreement. При одинаковых входах b все полученные биты равны b, так что validity выполнена. Каждый неотказавший завершает синхронный раунд и решает, то есть termination.

Если процесс может остановиться посреди рассылки, предпосылка об общем множестве отправителей исчезает. Например, процесс с 0 успевает отправить его только одному из двух процессов с 1. Если каждый решит минимум увиденного после первого раунда, получатель 0 решит 0, другой — 1. Это ошибка конкретного протокола, не доказательство невозможности consensus в такой модели.

3. Двухраундная ретрансляция при одном отказе

Определение 11.5 (частичная рассылка при crash). В каждом синхронном раунде процесс может отправить сообщение любому подмножеству адресатов и затем навсегда остановиться. Отправленные сообщения доставляются к концу раунда; неотказавший процесс отправляет всем. Во всём исполнении допускается не более одного crash. Сообщение может содержать до n пар (i, x_i).

Алгоритм 11.6 (relay). В первом раунде каждый процесс рассылает собственную пару (i, x_i). Во втором каждый ещё работающий процесс рассылает всем все пары, полученные в первом раунде, и собственную пару. После второго раунда неотказавший процесс берёт объединение всех увиденных пар и решает минимум их битов.

Лемма 11.7 (одинаковый набор). После второго раунда каждый неотказавший процесс знает один и тот же набор пар.

Доказательство. Рассмотрим произвольный источник пары p. Если p не отказал, его пара дошла до всех уже в первом раунде. Если p отказал, никто другой не может отказать, поскольку разрешён один crash. Если хотя бы один неотказавший получил пару p в первом раунде, он передаст её всем во втором. Если никто не получил, пары нет ни у одного неотказавшего. Таким образом, принадлежность пары p набору одинакова для всех неотказавших. Повторяем для каждого p.

Теорема 11.8. Алгоритм 11.6 решает binary consensus среди неотказавших за два раунда при не более одном crash посреди рассылки.

Доказательство. Набор пар по лемме 11.7 одинаков и непуст, потому что содержит собственные пары исправных процессов. Минимум одинаков — agreement. Если все исходные входы равны b, любая доступная пара содержит b, значит, решение равно b — validity. Исправные процессы завершают оба синхронных раунда и решают — termination.

Пример. Если процесс с 0 успел сообщить его одному адресату и упал, этот адресат уже не может упасть при бюджете одного crash и ретранслирует 0 всем. При двух crash второй адресат может упасть посреди второго раунда; тогда наборы у оставшихся процессов различаются и доказательство ломается. Чтобы получить протокол при большем f, нужна новая схема и анализ скрытых цепочек сообщений.

4. Стоимость связи и область применимости

Во втором раунде один процесс может переслать n пар; если ID имеют $O(\log n)$ бит, одно сообщение занимает $O(n \log n)$ бит, а на полной сети суммарно может быть $O(n^3 \log n)$ бит. Поэтому «два раунда» здесь не означает «два раунда CONGEST на произвольном графе». Если полная сеть реализована маршрутами по исходному графу, нужно учитывать длину маршрутов и нагрузку рёбер из лекции 09.

Определение 11.9 (кворум). При $n = 2f + 1$ множество размера не менее $f+1$ называется большинством. Любые два большинства пересекаются, поскольку иначе их объединение содержало бы хотя бы $2f + 2 > n$ различных процессов.

Доказательство. Для множеств Q_1, Q_2 размера не менее $f + 1$ формула $|Q_1 \cap Q_2| = |Q_1| + |Q_2| - |Q_1 \cup Q_2|$ даёт нижнюю оценку $2f + 2 - n = 1$.

Пересечение кворумов само по себе не решает consensus: общий процесс может быть отказавшим либо мог хранить разные данные в разные моменты. Для безопасности протокола нужно ещё доказать, что информация, однажды закреплённая в пересечении, не теряется при последующих шагах. Эту разницу полезно помнить при чтении протоколов Paxos, но их доказательство в текущую лекцию не включено. Обсуждение границы синхронной и асинхронной моделей: FLP, §1–2.

5. Два значения validity и пересечение кворумов

Для бинарной задачи unanimity validity выглядит слабее требования «решённое значение было чьим-то входом». На полном множестве бинарных входов эти требования на самом деле совпадают, если выход тоже обязан быть битом.

Лемма 11.10 (бинарная эквивалентность). При $x_i, d \in \{0, 1\}$ unanimity validity эквивалентна условию $d \in \{x_1, \dots, x_n\}$ для всякого решения d.

Доказательство. Если все входы равны b, условие принадлежности допускает только b, значит, влечёт unanimity validity. Обратно, если входы не все равны, среди них есть и 0, и 1; любое допустимое бинарное решение принадлежит множеству входов автоматически. Если входы все равны b, unanimity validity заставляет решить b, который является входом. Значит, обратное направление тоже верно.

Для трёхзначных входов эквивалентность пропадает. На входе $(0, 1)$ условие единогласия не накладывает ограничений, и решение 2 удовлетворяет ему, но не условию «предложено кем-то». Поэтому при расширении протокола с бинарных на общие значения нельзя механически переносить старое доказательство validity.

Пересечение кворумов из определения 11.9 тоже требует дополнительного инварианта. Пусть $n = 3$, большинство имеет размер 2, а множества $Q_1 = \{a, b\}$ и $Q_2 = \{b, c\}$ пересекаются в b. Если b успел ответить на разные запросы значениями 0 и 1 в два разных момента, само пересечение не запрещает двум лидерам получить противоречивые «подтверждения». Протокол должен ограничить, какие ответы b вправе выдавать после обещания или решения. Если b отказал между фазами, нужно ещё обеспечить, что достаточная информация уже осталась у исправных участников. Это и есть причина, по которой простая комбинаторная лемма не превращается сама по себе в доказательство consensus.

Пример проверки модели. Для алгоритма 11.6 каждое сообщение второго раунда может содержать n входных пар, поэтому стоимость $O(n \log n)$ бит на канал остаётся существенной даже при двух раундах. Для QUORUM-протокола число фаз может быть маленьким, но приходится отдельно доказывать монотонность принятых значений. Сравнение моделей отказов и сообщений: FLP, §1–2.

Проверка понимания. В каждом доказательстве найдите точное место, где используется: (i) верхняя граница задержки одного раунда; (ii) бюджет отказов; (iii) правило «отправил всем или никому»; (iv) размер сообщения. Изменение любого из этих параметров требует новой теоремы.